



AI engineering tools 7

Шаповалов Александр

aTCL






Шаповалов Александр

aTCL @ Internal automation

- Вижу, как медленно внедряется AI в бигтехе
- tg: @rostish




Тестирование



Сегодня узнаете

1. Классическое тестирование с использованием AI-инструментов.
2. Тестирование агентов.



R1. Классическое тестирование

2




2


3

4


Пирамида тестирования



Распределение усилий по пирамиде



Unit-тесты: основание пирамиды




Unit-тесты: основание пирамиды




Integration-тесты: середина пирамиды



E2E-тесты: вершина пирамиды



LLM-as-Judge



R2. Тестирование агентов

2




2

3

4

Как тестировать агентов?




Как тестировать агентов?



Бенчмарки

Иерархия тестов LLM-систем



Unit-тесты промптов

Что это?

Проверка одного input → output по чётко определённому критерию. Аналог unit-test в обычном программировании, но output недетерминирован.

Метрики оценки

- Correctness — точность ответа
- Coherence — связность текста
- Toxicity / Safety
- Format compliance (JSON, markdown...)



DeepEval — пример

```
from deepeval import assert_test
from deepeval.metrics import
    AnswerRelevancyMetric

metric = AnswerRelevancyMetric(
    threshold=0.7)

test_case = LLMTestCase(
    input="Как работает RAG?",
    actual_output=llm_response
)

assert_test(test_case, [metric])
```

RAG-тестирование



Faithfulness

Все утверждения ответа
подтверждены контекстом

0 → 1

Answer Relevancy

Ответ релевантен вопросу
пользователя

0 → 1

Context Recall

Весь нужный контекст был
извлечён

0 → 1

Context Precision

Нет лишнего шума в
retrieved chunks

0 → 1

Ключевые trade-offs в RAG:

↑ Context Recall vs ↑ Context Precision → больше чанков = больше шума

↑ Faithfulness vs Creativity / Coverage → строгая привязка = потеря обобщений

Agent Testing

⚠️ Агент ≠ одиночный LLM-вызов. Тестировать нужно весь chain:
planning → tool selection → execution → observation → result

Task Completion

- Success Rate (SR) — достиг цели?
- Task Goal Completion (TGC)
- Pass@k — успех в k попытках

Tool Correctness

- Правильный инструмент выбран?
- Аргументы корректны?
- Tool call accuracy (RAGAS)

Efficiency

- Step count vs optimal path
- Token cost per task
- Time-to-completion

Red Teaming

Категории атак

- 

Prompt Injection

Вредоносные инструкции внутри пользовательского ввода
- 

Jailbreak

Обход системных ограничений через roleplay / encoding
- 

PII Leakage

Утечка персональных данных из training data
- 

Hallucination

Намеренное провоцирование ложных утверждений
- 

Bias / Toxicity

Генерация дискриминирующего или вредоносного контента

Инструменты

- Promptfoo

★★★★★

50+ red-team плагинов. YAML-конфиги, CI/CD. Лучший для security.
- DeepEval

★★★★☆


40+ категорий уязвимостей. Встроен в pytest workflow.
- Garak

★★★★☆

Open-source LLM vulnerability scanner от NVIDIA.

Regression Testing

Запускать весь набор тест-кейсов при каждой итерации: смена промпта, замена модели, обновление кода.



Что вызывает регрессию?

- Изменение системного промпта
- Новая версия модели (GPT-4o → GPT-5)
- Обновление RAG-индекса
- Изменение post-processing логики
- Новые tools / функции агента

Платформы:

Braintrust

Experiment versioning, CI gates, production monitoring

DeepEval / Confident AI

pytest-based regression suite + cloud dashboard

Langfuse

Open-source, OTel, self-hosted — хорош для privacy

Источники

arxiv 2503.16416	Survey on Evaluation of LLM-based Agents (Yehudai et al., 2025)
KDD 2025	Evaluation and Benchmarking of LLM Agents (Mohammadi et al.)
NeurIPS 2023	Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena (Zheng et al.)
EACL 2024	RAGAS: Automated Evaluation of Retrieval Augmented Generation (Es et al.)
ICLR 2024	SWE-bench: Can Language Models Resolve Real-World GitHub Issues? (Jimenez et al.)
METR 2025	Measuring AI Ability to Complete Long Tasks — metr.org/blog/2025-03-19
ICLR 2024	AgentBench: Evaluating LLMs as Agents (Liu et al.)
arxiv 2508.08285	The Illusion of Progress: Re-evaluating Hallucination Detection (2025)

РЗ. Бенчмарки

2



2

3

4

Что это такое?



Бенчмарк — это стандартизированный тест с известным правильным ответом
Модель получает задачу (функцию, баг, сценарий), генерирует решение, решение автоматически проверяется. Результат — процент пройденных задач. Это позволяет сравнивать модели объективно, без субъективных оценок.

ПОЧЕМУ ИМЕННО ЭТОТ СПОСОБ?

 **Автоматизация**
Запускается без людей. Тысячи задач за минуты. Для ручной оценки потребовались бы месяцы.

 **Воспроизводимость**
Один и тот же тест — одинаковые условия для всех моделей. Нет субъективности «это хороший код?».


 **Отслеживание прогресса**
Одни и те же задачи в 2021 и 2026 — видно, насколько выросли возможности за время.

 **Целевая функция для обучения**
Модели дообучают, чтобы улучшить результат на конкретном бенчмарке. Бенчмарк стал «целью».


КАК РАБОТАЕТ ТИПИЧНЫЙ CODING BENCHMARK

Метрика Pass@k
Модель делает k попыток решить задачу. Если хотя бы одна прошла все тесты — задача засчитана. Pass@1 = одна попытка. Pass@10 = из 10 попыток хотя бы одна верная. Чем выше k — тем лучше выглядит модель.


Главная проблема: бенчмарки проверяют «проходит ли код тесты», но не «хороший ли это код». Читаемость, поддерживаемость, безопасность — за рамками любого benchmark.




Эволюция бенчмарков



Эволюция бенчмарков




Benchmark contamination




- КЛЮЧЕВЫЕ ПРОБЛЕМЫ БЕНЧМАРКОВ
- Утечка данных (contamination).** Задачи из HumanEval и SWE-bench Verified попали в обучающие данные моделей. Высокий результат может означать «модель видела это», а не «модель умеет это».
- Benchmark ≠ production.** Модель решает 80% SWE-bench, но в реальном проекте может давать код с уязвимостями, нечитаемый, несовместимый с code review. Бенчмарк не измеряет качество.
- Стоимость не измеряется.** Модель с 80% и ценой \$2/задачу хуже, чем модель с 75% и \$0.20. Ни один топовый бенчмарк не публикует \$/task.
- Ответ индустрии:** живые бенчмарки (LiveCodeBench, SWE-bench Live) с задачами после даты обучения, более сложные сценарии (Pro, Enterprise-уровень), агентные бенчмарки с многошаговыми задачами.

Benchmark contamination



Тренд: доля динамических бенчмарков



* оценка на основе публичных leaderboard данных

Кризис бенчмарков

“ У нас настоящий кризис оценки. Я не знаю, на какие метрики смотреть. MMRU был полезен несколько лет, но это давно в прошлом.

— Андрей Карпатый, март 2025



Air Canada

Проиграла суд — чатбот придумал несуществующую скидку на билеты



NYC Gov

Чатбот мэрии давал незаконные советы владельцам бизнеса




7 семей

Судятся с OpenAI — чатботы провоцировали самоповреждение


Все эти инциденты можно было предотвратить грамотной оценкой системы до деплоя

Кризис бенчмарков

Performance on CursorBench



Кризис бенчмарков



Пробелы и направления

Гранулярная оценка

Бенчмарки дают только бинарный результат. Нужен пошаговый анализ: выбор инструмента, качество рассуждения, промежуточные решения.

Развивается

Стоимость и эффективность

Оценки игнорируют токены, время инференса и API-расходы. Результат — мощные, но нежизнеспособные агенты.

Критический пробел

Масштабирование оценки

Ручная разметка не масштабируется. Перспективы: синтетическая генерация тестов и подход Agent-as-a-Judge.

Развивается

Безопасность и compliance

Adversarial-атаки, предвзятость, политики почти не тестируются. Особенно критично для мультиагентных систем.

Критический пробел

Кризис бенчмарков


<https://habr.com/ru/companies/bothub/articles/1014096/>





Что же делать в кризис?

Что же делать в кризис?



Писать свои
бенчмарки!!!

Что же делать в кризис?



Задавать
проверочные
вопросы

Что же делать в кризис?

●

Насыщен ли бенчмарк?

Если топ-модели дают 90%+ — он уже не дифференцирует. Ищи более свежий.

●

Self-reported или верифицирован?

Независимая проверка (Epoch AI, Scale AI) — в разы ценнее авторского отчёта.

●

Есть ли утечка данных?

Задачи старше года из популярных репо — почти наверняка в обучающих данных.

●

Указана ли цена за задачу?

Нет \$/task рядом с % — это полная картина наполовину. Требуй оба числа.

●


Соответствует ли задаче?

SWE-bench ≠ E2E тесты ≠ юнит-тесты. Проверяй, что именно измеряет бенчмарк.

●


Свежие ли задачи?

LiveCodeBench, SWE-bench Live — задачи после даты обучения. Это чище.



Агентное тестирование. Таксономия оценки

Таксономия оценки агентов (arxiv 2503.16416)



Таксономия оценки агентов

1	Базовые способности Планирование, инструменты, саморефлексия, память — GSM8K, BFCL, Reflection-Bench, MemGPT
2	Прикладные агенты Веб (WebArena), SWE (SWE-bench), научные (SciCode), диалоговые (т-Bench, IntellAgent)
3	Универсальные агенты GAIA, OSWorld, TheAgentCompany, CRMArena, HAL — разнородные задачи в реалистичных средах
4	Фреймворки оценки LangSmith, Vertex AI, Galileo, BrowserGym — мониторинг, пошаговый анализ, A/B-тесты

Каждый уровень оценивается с разной гранулярностью: **финальный ответ** → **пошагово** → **траектория** → **A/B**

METR: время задач агентов растёт


x2

каждые 7 месяцев

длина задач, которые агенты
решают с 50% надёжностью


METR, март 2025 · 6 лет данных

Эволюция time horizon агентов



♦ Claude Opus 4.5 — 4 ч 49 мин (METR, 2025)

LLM-as-Judge: основа современных бенчмарков



✓ Преимущества

- Масштабируется без людей
- Гибкие критерии оценки
- Работает для open-ended задач
- Объясняет причину оценки

⚠ Ограничения

- Self-enhancement bias (модель хвалит себя)
- Position bias (порядок ответов важен)
- Зависит от качества judge-модели

🔬 Исследования

- ROUGE — опасно низкая precision
- LLM-judge ≈ human при правильном промпте
- GPT-4o-mini — лучший cost/quality баланс

Summary

1



2

3

4

Выводы

Кризис бенчмарков — статические типа MMLU мертвы, нужны динамические бенчмарки

Выводы

Кризис бенчмарков — статические типа MMLU мертвы, нужны динамические бенчмарки

Агентное тестирование — отдельная дисциплина с таксономией из 4 измерений. Для каждого измерения - свой инструмент.

Выводы

Кризис бенчмарков — статические типа MMLU мертвы, нужны динамические бенчмарки

Агентное тестирование — отдельная дисциплина с таксономией из 4 измерений. Для каждого измерения - свой инструмент.

Пишите свои бенчмарки.

Источники

NeurIPS 2023	Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena (Zheng et al.) · arxiv.org/abs/2306.05685
arxiv 2503	Survey on Evaluation of LLM-based Agents (Yehudai et al., 2025) · arxiv.org/abs/2503.16416
METR 2025	Measuring AI Ability to Complete Long Tasks · metr.org/blog/2025-03-19
arxiv 2508	The Illusion of Progress: Re-evaluating Hallucination Detection in LLMs · arxiv.org/abs/2508.08285